ACTIVIDAD 6

Materia:	Gestión de Proyectos de Inteligencia Artificial
Actividad:	Actividad 6
Alumno(a):	Katya Márquez Márquez
Matrícula:	7182959
Docente:	Profre: Luis Uriel Vázquez Piña
Fecha de entrega:	23/Octubre/2026

Declaración de Uso de Inteligencia Artificial

El alumno debe indicar de manera honesta si utilizó herramientas de Inteligencia Artificial (IA) para el desarrollo de esta actividad. Completa la siguiente tabla:

Herramienta de IA utilizada	¿La usaste?	Propósito / Descripción de uso
ChatGPT / OpenAI	✓ Sí ☐ No	Complemento de código en python
Claude (Anthropic)	☐ Sí ✓ No	
Gemini (Google)	✓ Sí ☐ No	Primera versión de código en python
Copilot (Microsoft)	☐ Sí ✓ No	
Otra (especifica):	☐ Sí ✓ No	

Desarrollo de Contenido

1. Objetivo

Analizar un problema de clasificación aplicado, ya sea en contextos clínicos, financieros o sociales, y desarrollar un proceso completo de evaluación y validación de un modelo de *Machine Learning*.

2. Reporte técnico

Modelo de detección de fraude bancario

Definición del problema y contexto

Este proyecto tiene como objetivo desarrollar y evaluar un modelo experimental de aprendizaje automático para identificar posibles transacciones fraudulentas y analizar su utilidad potencial en el sector bancario.

Dado que el impacto financiero y reputacional de omitir una transacción fraudulenta supera en gran medida el costo operativo de una verificación o un bloqueo preventivo, el modelo prioriza la métrica de **Recall (Sensibilidad)**. Para garantizar un equilibrio operativo y evitar un volumen excesivo de falsos positivos, se utiliza el **F1-Score** como métrica complementaria; el objetivo técnico consiste en maximizar el Recall manteniendo la Precisión en niveles óptimos.

En conclusión, el proyecto busca entregar un clasificador altamente eficiente que optimice la tasa de detección de fraude y permita calibrar su sensibilidad sin saturar la operación con alertas falsas.

Descripción del dataset y preparación de los datos

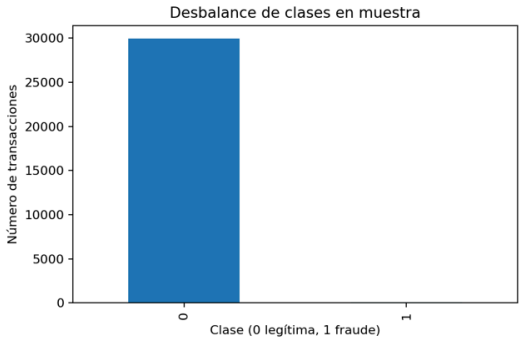
Se utilizazó el dataset público del sitio Kaggle: Credit Card Fraud Detection, el cual contiene **284,807 transacciones** de tarjetas europeas realizadas en septiembre de 2013, de los cuales **492 son fraudes (0.173%)**. El dataset tiene 31 campos, descritos de la siguiente forma:

Campo	Descripción
Class	0 legítima, 1 fraude
Time	Segundos desde la primera transacción
Amount	Importe
V1-V28	Componentes anonimizados por PCA

Se consideraron las siguientes validaciones y tratamiento para el conjunto de datos:

- Validación de columnas y etiquetas válidas
- Validación de valores nulos en la muestra

Se seleccionaron 30,000 registros mediante muestreo estratificado (52 fraudes) y se dividieron en entrenamiento (60%), validación (20%) y prueba (20%).

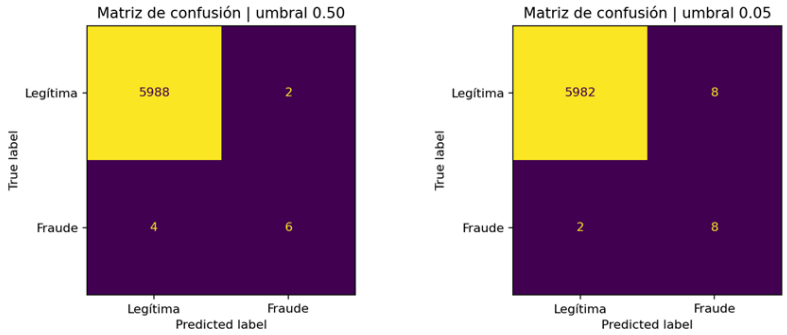


Matriz de Confusión, interpretación y ajuste del umbral

Se evaluaron cuatro clasificadores para la identificación de posibles transacciones fraudulentas:

- Regresión logística
- SVM con kernel RBF
- Random Forest
- Clasificador mayoritario de referencia.

Se seleccionó el modelo **Random Forest** considerando su *Average Precision* promedio mediante validación cruzada. Se compararon las predicciones en el conjunto de prueba utilizando un umbral estándar de **0.50** y un umbral optimizado de **0.05**. Este último determinado mediante un análisis de sensibilidad (en un rango de 0.05 a 0.95), orientado a minimizar el costo que penaliza con 10 unidades cada falso negativo y con 1 unidad cada falso positivo. Finalmente, el modelo se reentrenó con el conjunto de desarrollo completo y se evaluó en el conjunto de prueba definitivo.



Umbral 0.50 - Se detectaron 6 de 10 fraudes; 4 inadvertidos.

Umbral 0.05, se detectaron 8 de 10; los falsos positivos aumentaron de 2 a 8.

Se observa que un umbral menor favorece la cobertura de fraude a costa de precisión y F1

Cálculo e interpretación de métricas

Métrica	Umbral 0.50	Umbral 0.05
Accuracy	0.9990	0.9983
Precision	0.7500	0.5000
Recall	0.6000	0.8000
F1	0.6667	0.6154
ROC-AUC	94.70%	94.70%
Average Precision	60.68%	60.68%

Exactitud (Accuracy): El modelo clasifica correctamente más del 99% de las transacciones en ambos umbrales. Aunque, este resultado está influido por la gran cantidad de operaciones legítimas.

Precisión (Precision): Disminuye del 75% al 50%, lo que significa que, con el umbral de 0.05, una de cada dos transacciones señaladas como fraude es una falsa alarma.

Sensibilidad (Recall): Aumenta del 60% al 80%, permitiendo detectar 8 de cada 10 fraudes, en lugar de 6. Esto reduce los fraudes que pasan inadvertidos.

F1-score: Disminuye del 66.67% al 61.54%, indicando que el aumento en la detección de fraudes viene acompañado de una pérdida de precisión.

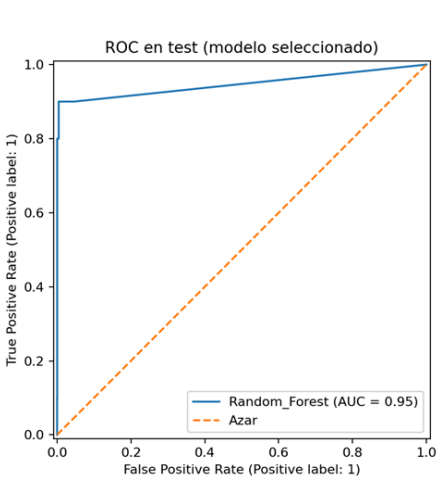
ROC-AUC: Alcanza el 94.70%, lo que indica una buena capacidad del modelo para distinguir entre transacciones legítimas y fraudulentas, independientemente del umbral seleccionado.

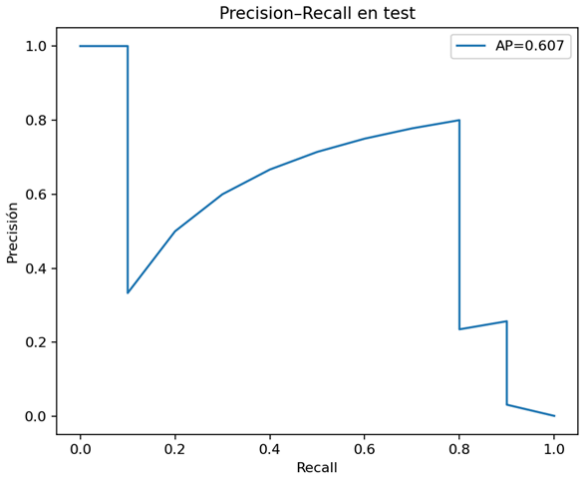
Average Precision: Obtiene un valor de 60.68%, que resume el equilibrio entre precisión y sensibilidad a diferentes umbrales. Es especialmente relevante porque los fraudes representan una proporción muy pequeña de las transacciones.

Conclusión: El umbral de 0.05 permite detectar más fraudes, aunque genera más falsas alarmas. Para el escenario y los costos del proyecto, este ajuste resulta favorable porque prioriza la detección de operaciones fraudulentas.

Curvas ROC, Precision-Recall y costos del modelo Random Forest

Para el modelo Random Forest seleccionado, el ROC-AUC final fue 0.9470 y el Average Precision fue 0.6068. Estas métricas no cambian modificando el umbral de clasificación. El AP de prueba es inferior al promedio de validación cruzada (0.8116), lo que sugiere más evaluaciones con más casos fraudulentos.





Para evaluar el impacto de los errores del modelo Random Forest, se asignó un costo hipotético de 10 unidades por cada fraude no detectado y de 1 unidad por cada transacción legítima clasificada incorrectamente como fraude. **Con el umbral de 0.50, el costo total fue de 42 unidades**, mientras que **con el umbral de 0.05 disminuyó a 28 unidades**. Esto representa una reducción del 33.3% en el costo estimado de los errores, lo que sugiere que el umbral ajustado ofrece un mejor equilibrio para el escenario evaluado.

Los costos utilizados son valores ilustrativos y no representan pérdidas monetarias reales.

Resultados de validación cruzada

Modelo	ROC-AUC	F1	Recall	AP
Random Forest	0.9505	0.8085	0.7238	0.8116
Regresión logística	0.9542	0.3451	0.8429	0.7794
SVM RBF	0.9877	0.2805	0.1857	0.4647
Dummy mayoritario	0.5000	0.0000	0.0000	0.0018

Se aplicó validación cruzada estratificada de cinco particiones para comparar los cuatro clasificadores. En cada partición se entrenó y evaluó el modelo, calculando el promedio y la variación de sus métricas.

Los resultados de la validación cruzada muestran que cada modelo destacó en diferentes métricas. **SVM obtuvo el mejor ROC-AUC**, lo que indica una mayor capacidad para distinguir entre transacciones legítimas y fraudulentas. **Random Forest alcanzó los mejores resultados en F1-score** (0.8085) **y Average Precision** (0.8116), mientras que **Regresión Logística logró detectar una mayor proporción de fraudes (recall).**

Se seleccionó **Random Forest** porque obtuvo el mejor Average Precision, esta métrica es muy útil cuando existen muy pocos casos de fraude en comparación con las transacciones legítimas.

Random Forest presentó una desviación estándar de 0.1093 en Average Precision, frente a 0.2740 de SVM. Esto indica que **Random Forest mostró resultados más consistentes entre las particiones de validación**. Sin embargo, debido al reducido número de fraudes disponibles, los resultados pueden variar entre particiones.

En conclusión, Random Forest fue seleccionado por su buen desempeño y mayor estabilidad, aunque se recomiendan más datos y análisis estadísticos.

Comparación con baseline

Se utilizó un modelo baseline que clasifica todas las transacciones como legítimas. Aunque obtuvo una exactitud elevada debido a la gran cantidad de operaciones no fraudulentas, su recall y F1-score fueron de cero, porque no detectó ningún fraude.

En comparación, Random Forest mostró una capacidad de detección considerablemente mayor. Esto confirma que una exactitud elevada no es suficiente para evaluar modelos de detección de fraude y que deben utilizarse métricas que consideren el desempeño sobre la clase minoritaria.

Análisis de pruebas A/B

Se realizó una prueba A/B simulada con dos grupos de 1,000 observaciones. El grupo A obtuvo una tasa de éxito del 67.8% y el grupo B del 87.2%, con una diferencia de 19.4 puntos porcentuales. La prueba estadística mostró una diferencia significativa ($p = 2.80 \times 10^{-25}$).

Sin embargo, las tasas se generaron a partir de probabilidades establecidas previamente y no de predicciones de Random Forest. Por tanto, el ejercicio permite demostrar el procedimiento de comparación estadística, pero no confirma una mejora real del modelo en producción.

La validación cruzada permite estimar el desempeño durante el desarrollo del modelo, mientras que una prueba A/B operativa requeriría comparar alternativas con grupos asignados de manera controlada.

Justificación técnica y su relación con el impacto en el negocio

La selección del modelo **Random Forest** se basó en los resultados de la validación cruzada, donde obtuvo el mejor Average Precision (0.8116) y F1-score promedio (0.8085). Estas métricas son relevantes para la detección de fraude, ya que permiten evaluar tanto la identificación de operaciones fraudulentas como la generación de falsas alarmas.

Desde el punto de vista del negocio, uno de los principales objetivos es **detectar la mayor cantidad posible de fraudes sin generar un número excesivo de revisiones innecesarias**. Los fraudes no detectados pueden ocasionar pérdidas económicas, mientras que las falsas alarmas pueden incrementar los costos operativos y afectar la experiencia de los clientes.

Por esta razón, se ajustó el umbral de decisión de 0.50 a 0.05, logrando incrementar la detección de fraudes del 60% al 80%. Aunque aumentaron los falsos positivos, el análisis de costos hipotéticos mostró una reducción del 33.3% en el costo estimado de los errores, pasando de 42 a 28 unidades.

Estos resultados sugieren que, **priorizar la detección de fraudes puede generar un beneficio mayor que el costo asociado a las revisiones adicionales**.

En un contexto bancario, el modelo podría apoyar la identificación de operaciones sospechosas, facilitar la priorización de alertas y contribuir a una mejor gestión del riesgo de fraude. Sin embargo, para determinar su utilidad real sería necesario considerar los costos operativos y el impacto en los clientes.

Conclusiones

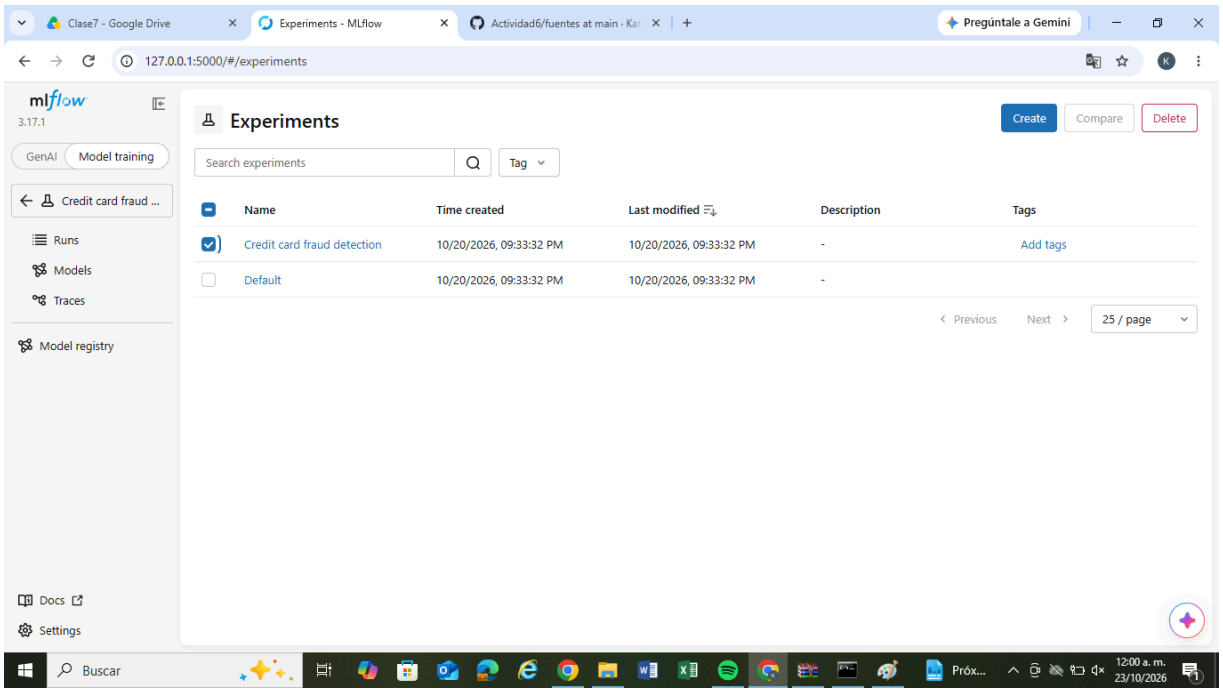
El proyecto permitió evaluar y comparar diferentes modelos de aprendizaje automático para la detección de fraude financiero, utilizando datos públicos de Kaggle. Random Forest fue seleccionado por obtener los mejores resultados promedio en Average Precision (0.8116) y F1-score (0.8085), mostrando un desempeño favorable frente al modelo baseline, que no logró detectar ningún fraude.

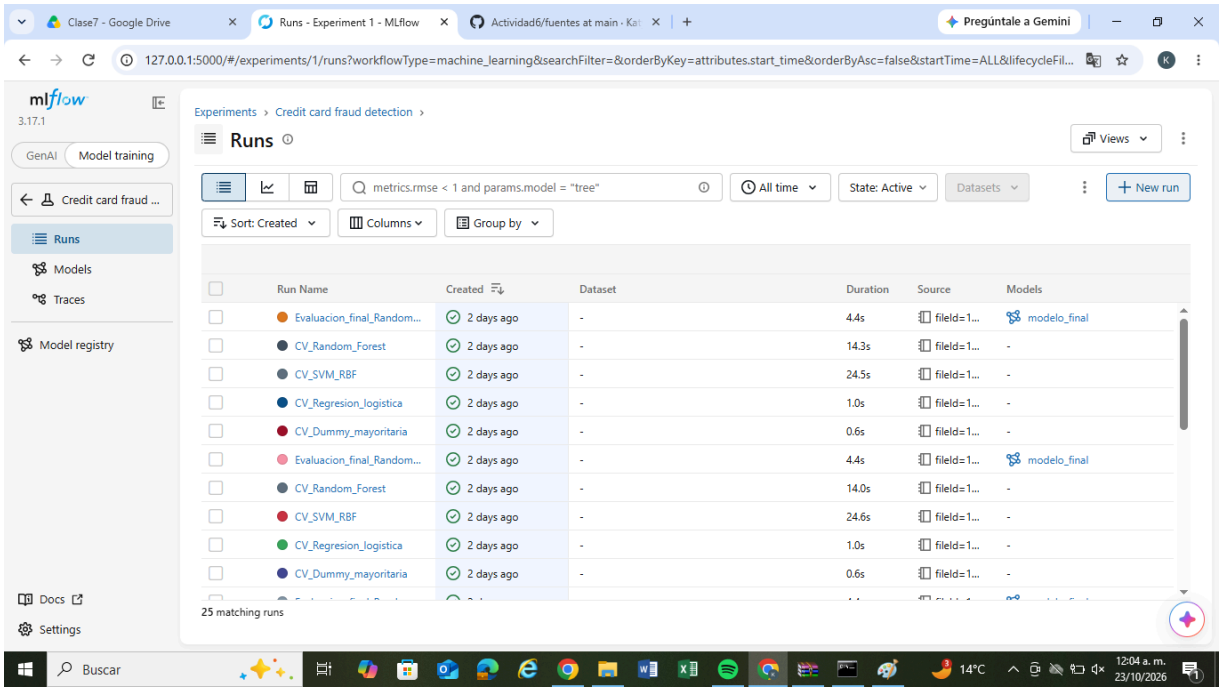
El ajuste del umbral de decisión de 0.50 a 0.05 permitió incrementar la detección de fraudes del 60% al 80%, aunque también aumentaron las falsas alarmas. Bajo los costos hipotéticos establecidos, este cambio redujo el costo estimado de los errores en un 33.3%, destacando la importancia de relacionar las decisiones técnicas con las necesidades del negocio.

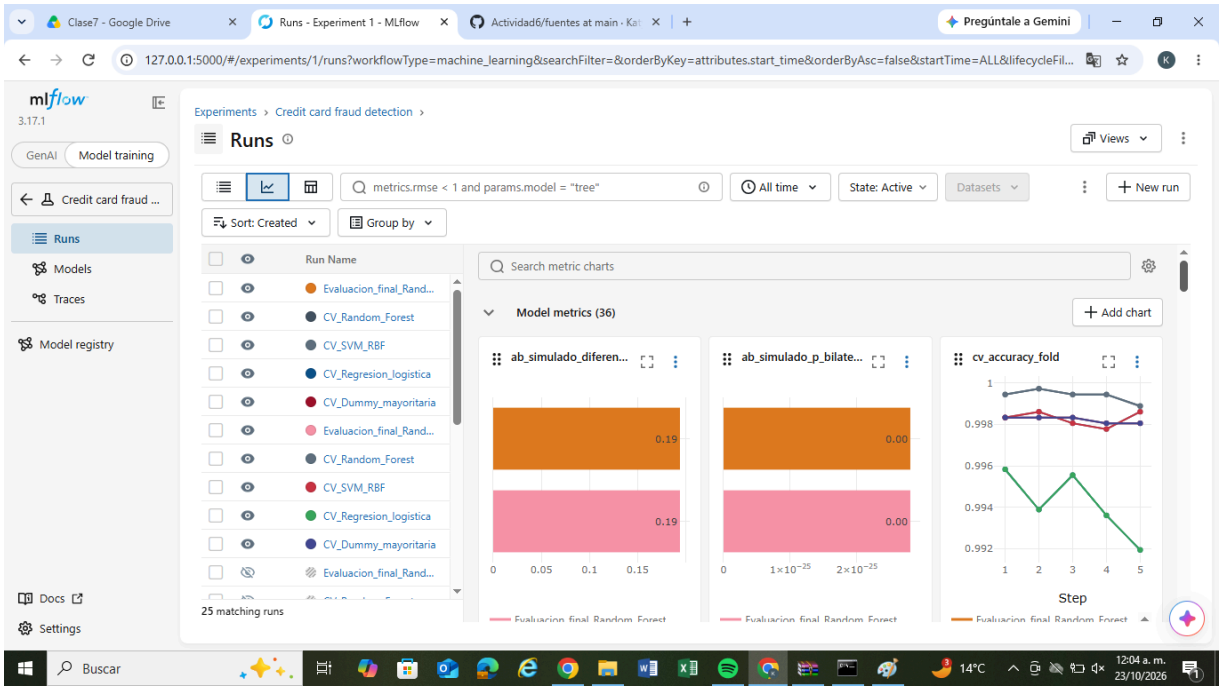
La validación cruzada permitió comparar el desempeño de los modelos, mientras que la simulación A/B mostró cómo evaluar diferencias estadísticas entre alternativas. Asimismo, MLflow facilitó el registro y seguimiento de los experimentos.

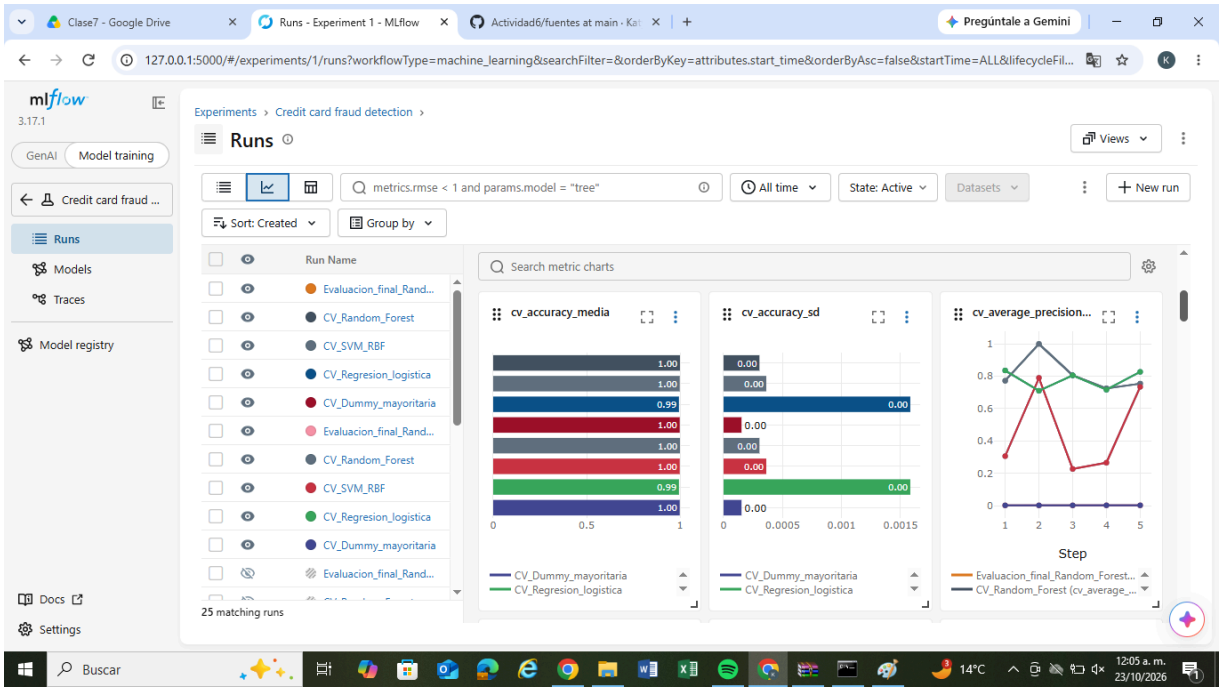
En conclusión, Random Forest representa una alternativa para apoyar la detección de fraude, aunque se requieren pruebas adicionales con datos más amplios y representativos antes de considerar su implementación real. El proyecto demuestra que una evaluación adecuada debe considerar tanto las métricas del modelo como su impacto potencial en el negocio.

Evidencia de uso de MLflow






Clase7 - Google Drive
Runs - Experiment 1 - MLflow
Actividad6/fuentes at main · Kat
Pregúntale a Gemini
127.0.0.1:5000/#/experiments/1/runs?workflowType=machine_learning&searchFilter=&orderByKey=attributes.start_time&orderByAsc=false&startTime=ALL&lifecycleFil...
mlflow
3.17.1
GenAI
Model training
Credit card fraud ...
Runs
Models
Traces
Model registry
Docs
Settings
Experiments › Credit card fraud detection ›
Runs
Views
metrics.rmse < 1 and params.model = "tree"
All time
State: Active
Datasets
New run
Sort: Created
Group by
Run Name
Evaluacion_final_Rand...
CV_Random_Forest
CV_SVM_RBF
CV_Regresion_logistica
CV_Dummy_mayoritaria
Search metric charts
Model metrics (36)
Add chart
ab_simulado_diferen...
ab_simulado_p_bilate...
cv_accuracy_fold
Step
25 matching runs
Buscar
14°C
12:04 a. m.
23/10/2026


Clase7 - Google Drive
Runs - Experiment 1 - MLflow
Actividad6/fuentes at main · Kat
Pregúntale a Gemini
127.0.0.1:5000/#/experiments/1/runs?workflowType=machine_learning&searchFilter=&orderByKey=attributes.start_time&orderByAsc=false&startTime=ALL&lifecycleFil...
mlflow
3.17.1
GenAI
Model training
Credit card fraud ...
Runs
Models
Traces
Model registry
Docs
Settings
Experiments › Credit card fraud detection ›
Runs
Views
metrics.rmse < 1 and params.model = "tree"
All time
State: Active
Datasets
New run
Sort: Created
Group by
Run Name
Evaluacion_final_Rand...
CV_Random_Forest
CV_SVM_RBF
CV_Regresion_logistica
CV_Dummy_mayoritaria
Search metric charts
cv_accuracy_media
cv_accuracy_sd
cv_average_precision...
Step
CV_Dummy_mayoritaria
CV_Regresion_logistica
Evaluacion_final_Random_Forest...
CV_Random_Forest (cv_average_...
25 matching runs
Buscar
14°C
12:05 a. m.
23/10/2026

Referencias

Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters, 27*(8), 861–874. https://doi.org/10.1016/j.patrec.2005.10.010

MLflow. (s. f.). *MLflow tracking*. https://mlflow.org/docs/latest/tracking

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830. https://www.jmlr.org/papers/v12/pedregosa11a.html

Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE, 10*(3), e0118432. https://doi.org/10.1371/journal.pone.0118432

Université Libre de Bruxelles. (s. f.). *Credit card fraud detection* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud